

Ejercicio de Evaluacion Parte II

Christopher Angel Rodriguez

FEB 8 2022

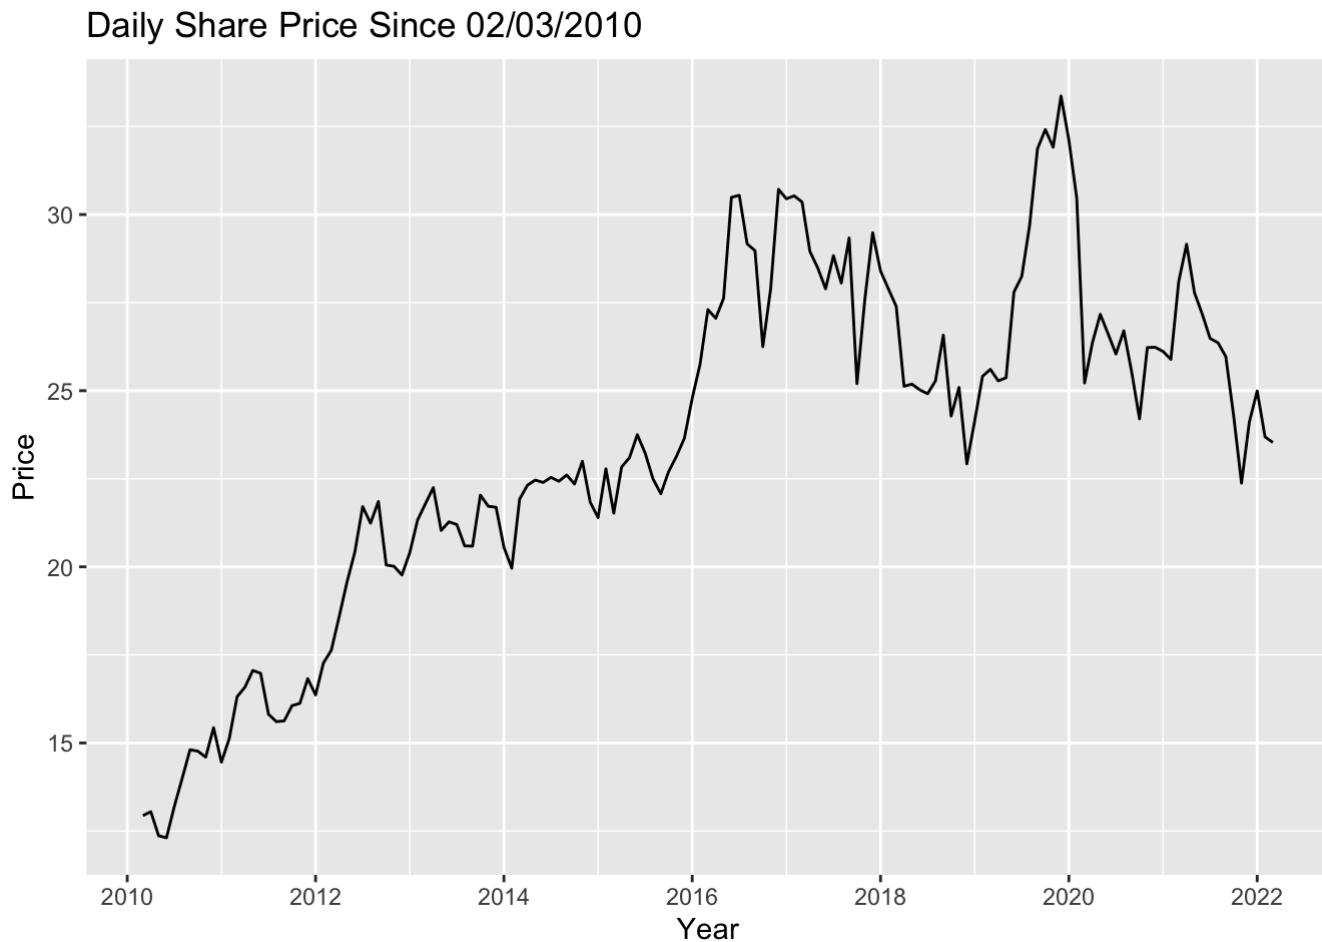
1. Presentacion de serie a analizar

La serie que estaremos evaluando en este apartado es del precio de las acciones de la compañía telefonica AT&T. AT&T Inc. es un conglomerado multinacional estadounidense que está registrado en Delaware pero tiene su sede en Whitacre Tower en el centro de Dallas, Texas. Es la compañía de telecomunicaciones más grande del mundo y el mayor proveedor de servicios de telefonía móvil en los EE. UU.

Estaremos evaluando un periodo de 12 años con observaciones del precio mensual de la acción.

2. Representación gráfica y descomposición estacional

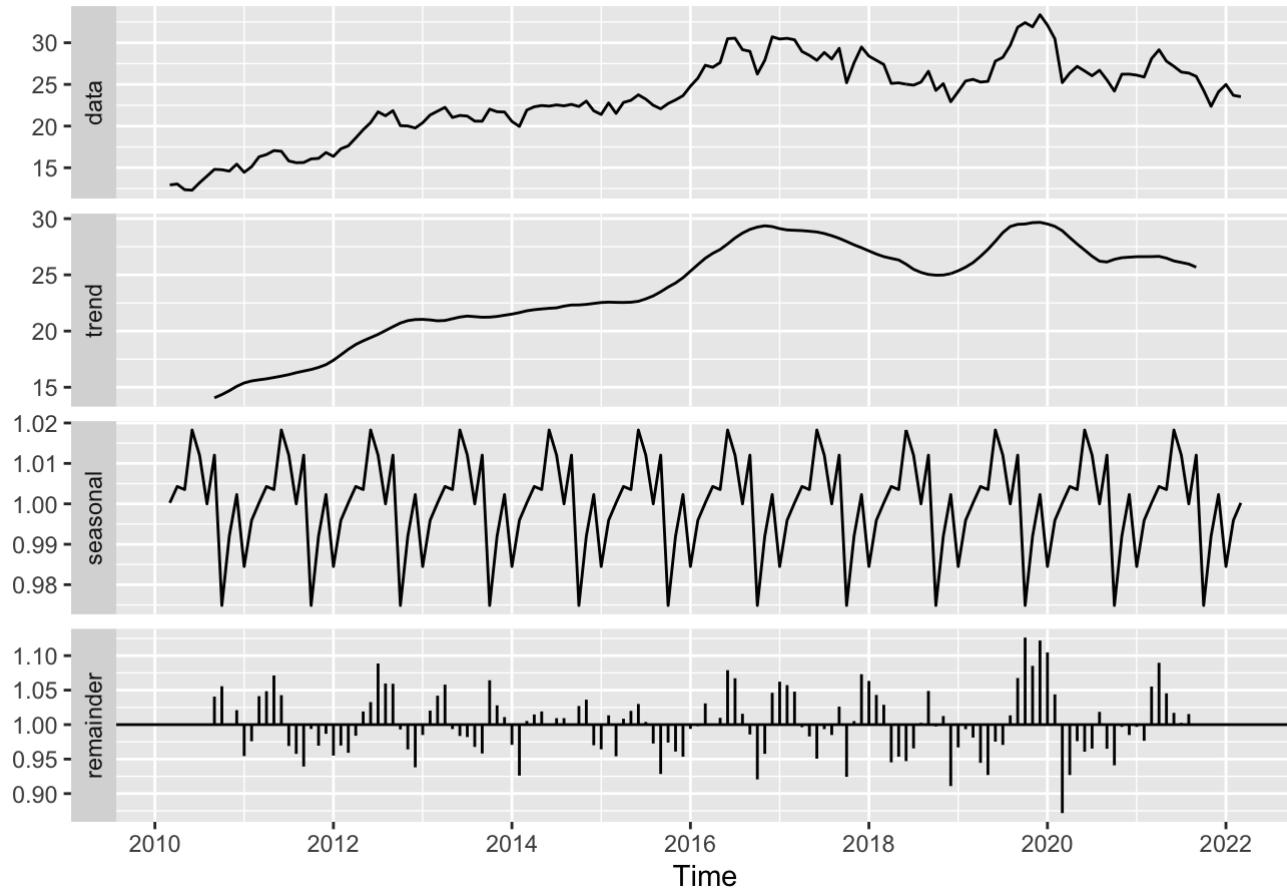
```
close <- ts(datos_ATT[,6], start=c(2010,03), frequency=12)
autoplot(close)+ggtitle('Daily Share Price Since 02/03/2010')+xlab('Year')+ylab('Price')
```



Nuestra serie presenta ser no estacionaria dado que no tiene media constante. A pesar de que desde el 2010 hasta mediados del 2016 presentaba una tendencia positiva creciente, a partir del 2017 no parece tener tendencia clara podemos argumentar que se ve hasta un poco decreciente. En adición podemos notar una fluctuación periódica donde parece que el precio de la acción disminuye durante los meses de noviembre.

```
close_decomp <- decompose(close,type = ('multiplicative'))
autoplot(close_decomp,ts.colour="blue")
```

Decomposition of multiplicative time series



Segun nuestro grafico, la estacionalidad del precio de la accion de AT&T parece ser anual porque se observa una tendencia que fluctua como punto minimo en noviembre y un valor alto durante el primer trimestre del año. Este patron se ve repetido a travez de los años.

```
knitr::kable(close_decomp$figure, digits = 2,caption = "Coef Estacionalidad")
```

Coef Estacionalidad

x
1.00
1.00
1.00
1.02
1.01
1.00
1.01

x

	x
	0.97
	0.99
	1.00
	0.98
	1.00

En adicon, El mes que presenta mayor el Precio de la Acción es el mes de Abril (coedf. estacional 1.02 %)mientras que tiene tendencia de precio mas bajo en agosto con un Coef.Estacionalidad de 0.97%

```
#Coroboramos si nuestra serie es estacional o no
nsdiffs(close)
```

```
## [1] 0
```

2. Nuestra serie NO es estacional, asi indicado por el apartado ' nsdiffs(close) = 0'

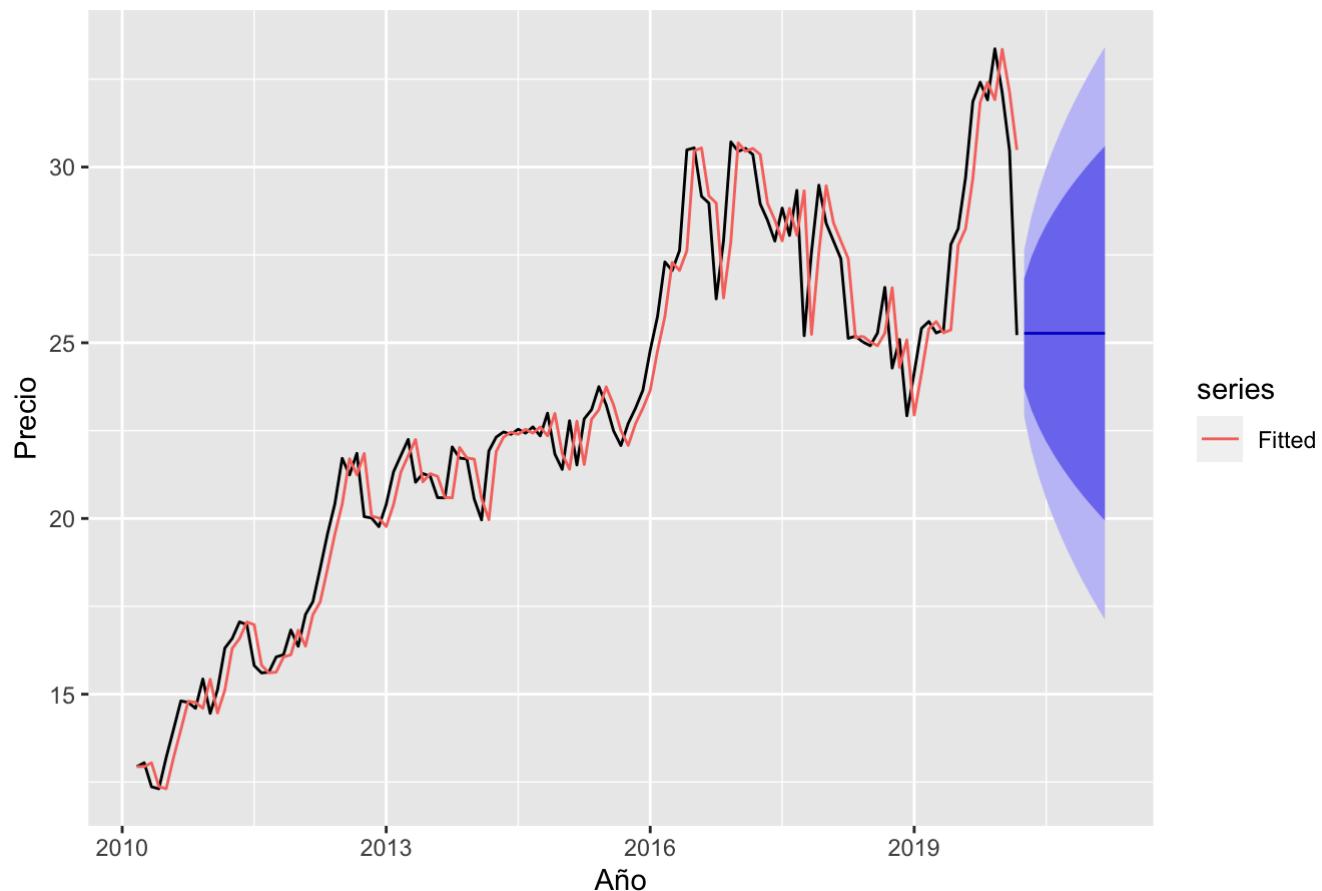
3.Para comprobar la eficacia de los métodos de predicción que vamos a hacer en los siguientes apartados reservamos los últimos datos observados

```
precio_entena <- window(close, end=c(2020,3))
```

4.Encontrar el modelo de suavizado exponencial más adecuado

```
#Suavizado Simple
precio_s<-ses(precio_entena, alpha=NULL, h=12)
autoplot(precio_s) + autolayer(fitted(precio_s), series="Fitted") + ylab("Precio") + xla
b("Año")
```

Forecasts from Simple exponential smoothing



```
knitr::kable(precio_s$model$par,digits = 3,caption = "Parametro de Modelos")
```

Parametro de Modelos

	x
alpha	0.991
	12.940

```
precio_s[["model"]]
```

```

## Simple exponential smoothing
##
## Call:
##   ses(y = precio_entena, h = 12, alpha = NULL)
##
##   Smoothing parameters:
##     alpha = 0.9905
##
##   Initial states:
##     l = 12.9398
##
##   sigma: 1.2103
##
##       AIC      AICC      BIC
## 630.4567 630.6618 638.8441

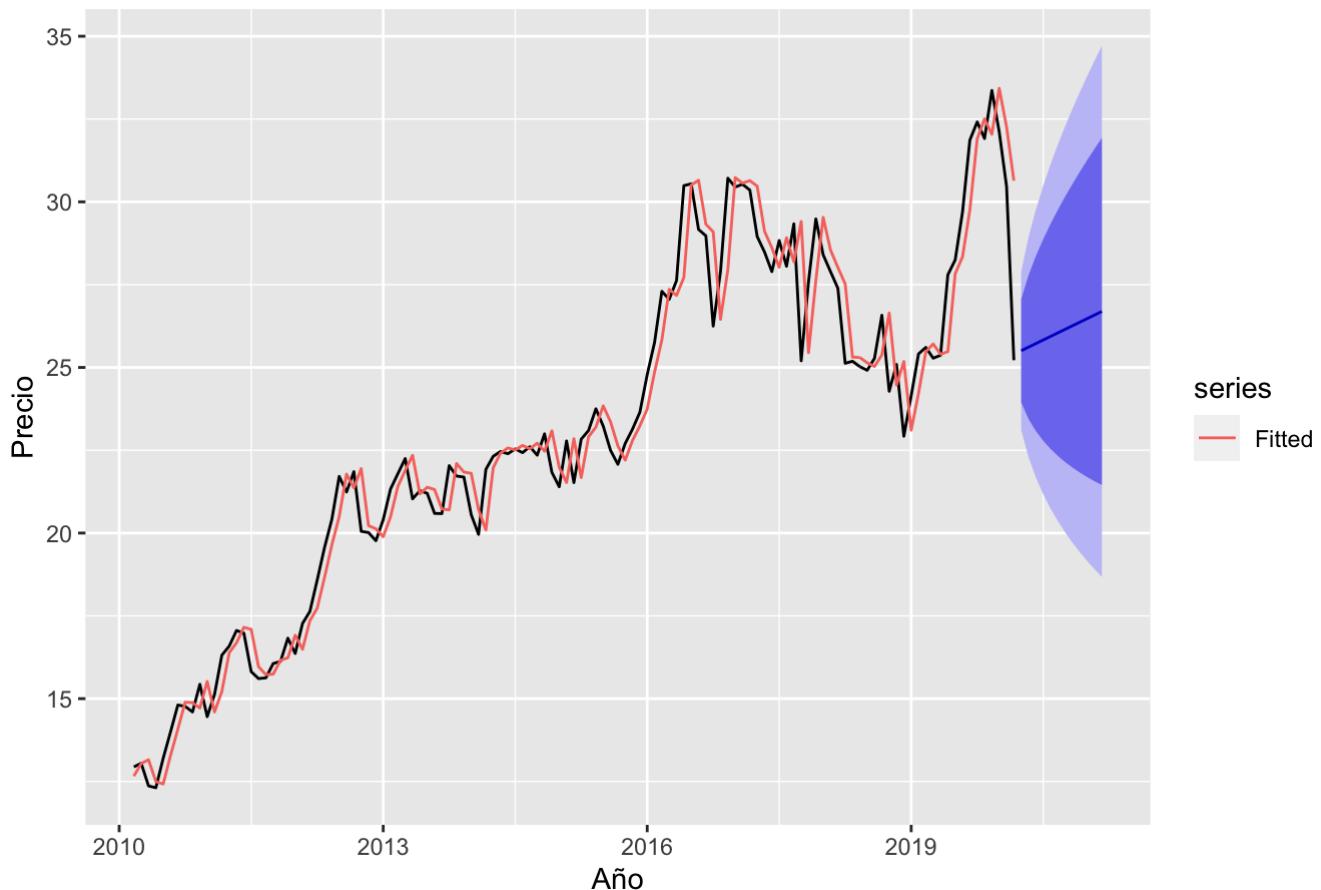
```

```

#Suavizado Holt
precio_h<-holt(precio_entena, h=12)
autoplot(precio_h) + autolayer(fitted(precio_h), series="Fitted") +ylab("Precio") + xlab
("Año")

```

Forecasts from Holt's method



```
knitr::kable(precio_h$model$par,digits = 4,caption = "Parametros Holt")
```

Parametros Holt

x

alpha	0.9670
beta	0.0001
l	12.5538
b	0.1077

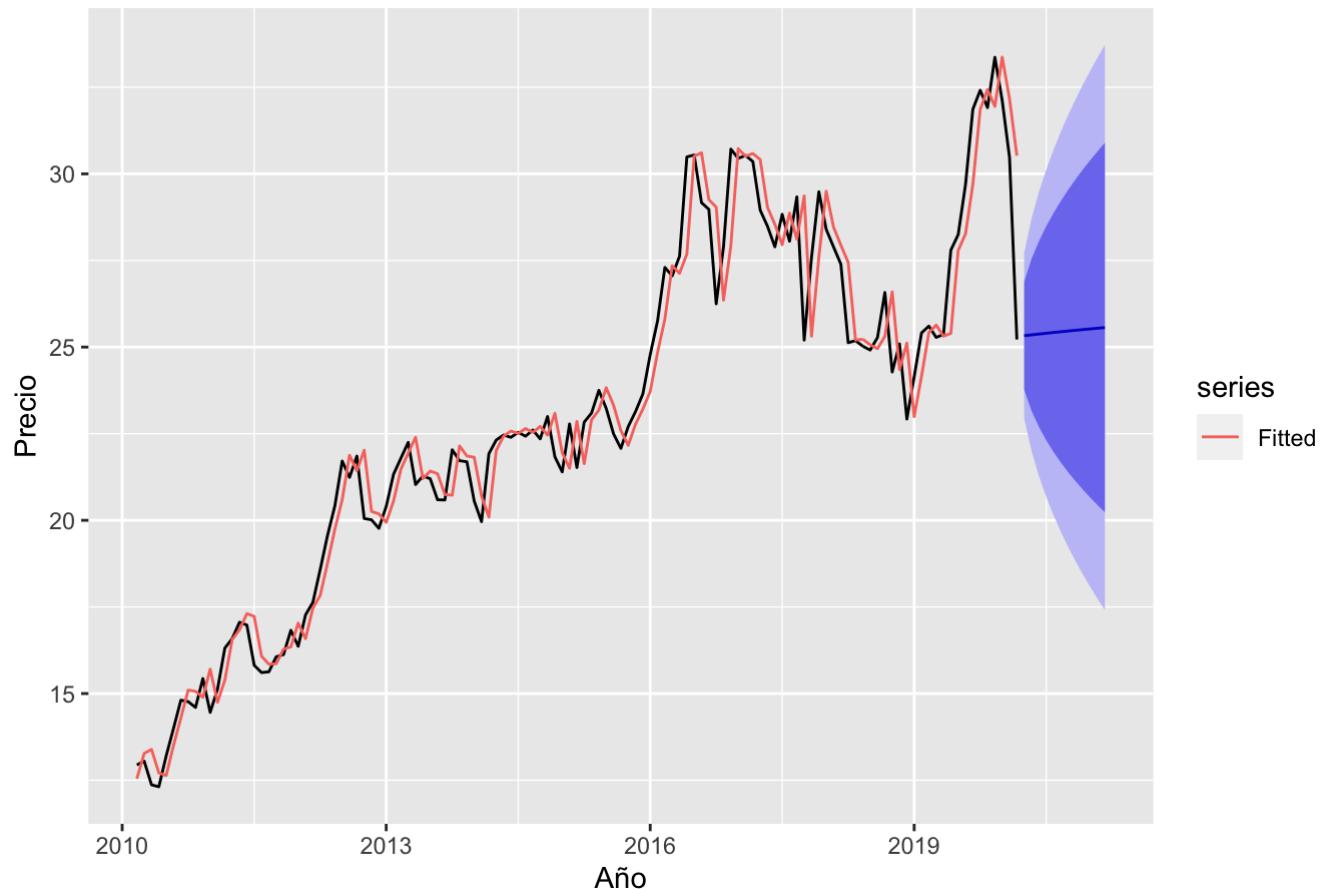
```
precio_h[["model"]]
```

```
## Holt's method
##
## Call:
##   holt(y = precio_entena, h = 12)
##
##   Smoothing parameters:
##     alpha = 0.967
##     beta  = 1e-04
##
##   Initial states:
##     l = 12.5538
##     b = 0.1077
##
##   sigma: 1.2164
##
##       AIC      AICC      BIC
## 633.6238 634.1456 647.6028
```

#Suavizado Holt Amortiguado

```
precio_hd<-holt(precio_entena, damped=TRUE, h=12)
autoplot(precio_hd) + autolayer(fitted(precio_hd), series="Fitted") + ylab("Precio") + xlab("Año")
```

Forecasts from Damped Holt's method



```
knitr::kable(precio_hd$model$par,digits = 3,caption = "Parametros Damped Holt")
```

Parametros Damped Holt

	x
alpha	0.984
beta	0.000
phi	0.978
	12.194
b	0.356

```
precio_hd[['model']]
```

```

## Damped Holt's method
##
## Call:
##   holt(y = precio_entena, h = 12, damped = TRUE)
##
##   Smoothing parameters:
##     alpha = 0.9838
##     beta  = 1e-04
##     phi   = 0.9783
##
##   Initial states:
##     l = 12.1942
##     b = 0.3563
##
##   sigma: 1.2185
##
##       AIC      AICc      BIC
## 635.0052 635.7420 651.7799

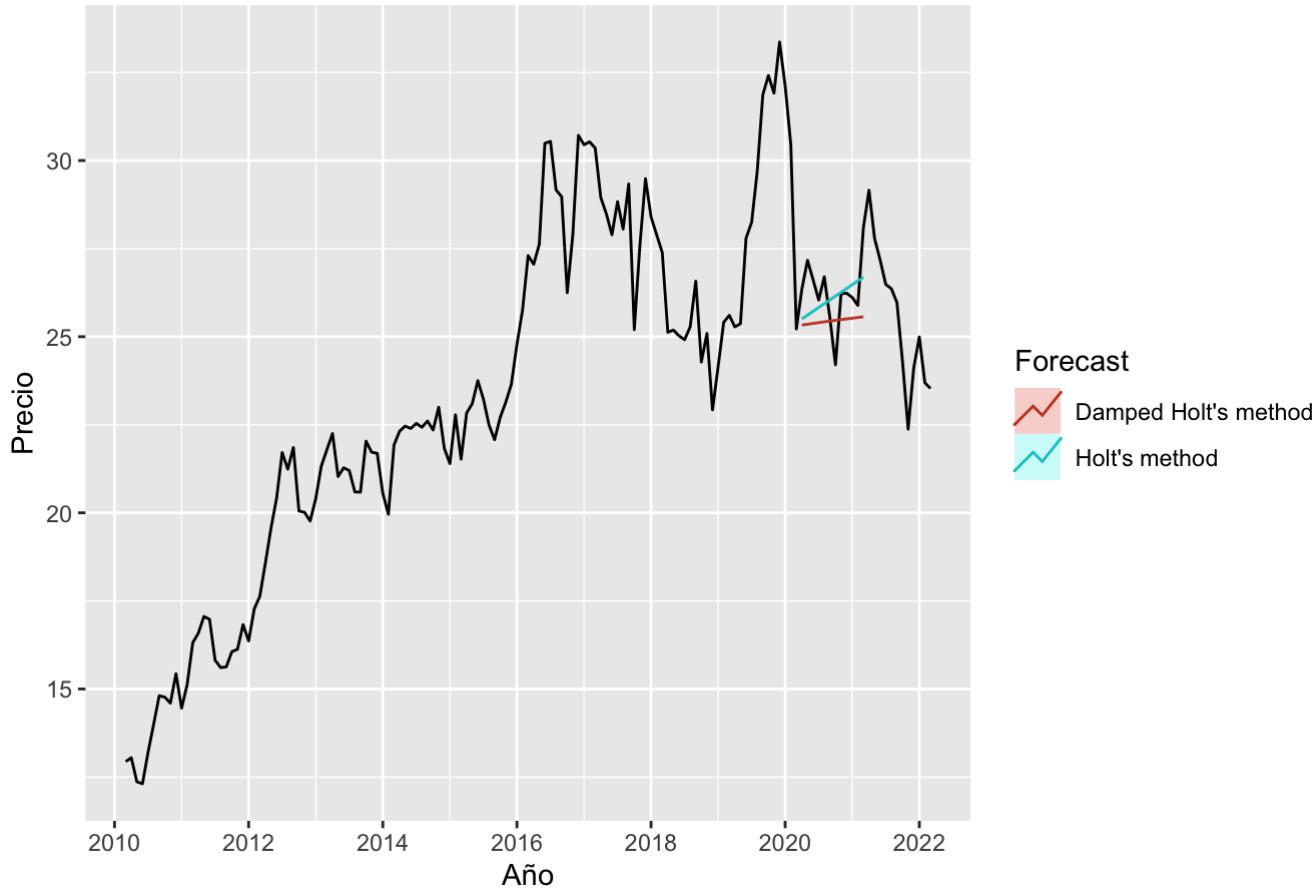
```

```

autoplot(close) + autolayer(precio_h, series="Holt's method", PI=FALSE) +
  autolayer(precio_hd, series="Damped Holt's method", PI=FALSE) +
  ggtitle("Forecasts from Holt's method") + xlab("Año") + ylab("Precio") +
  guides(colour=guide_legend(title="Forecast"))

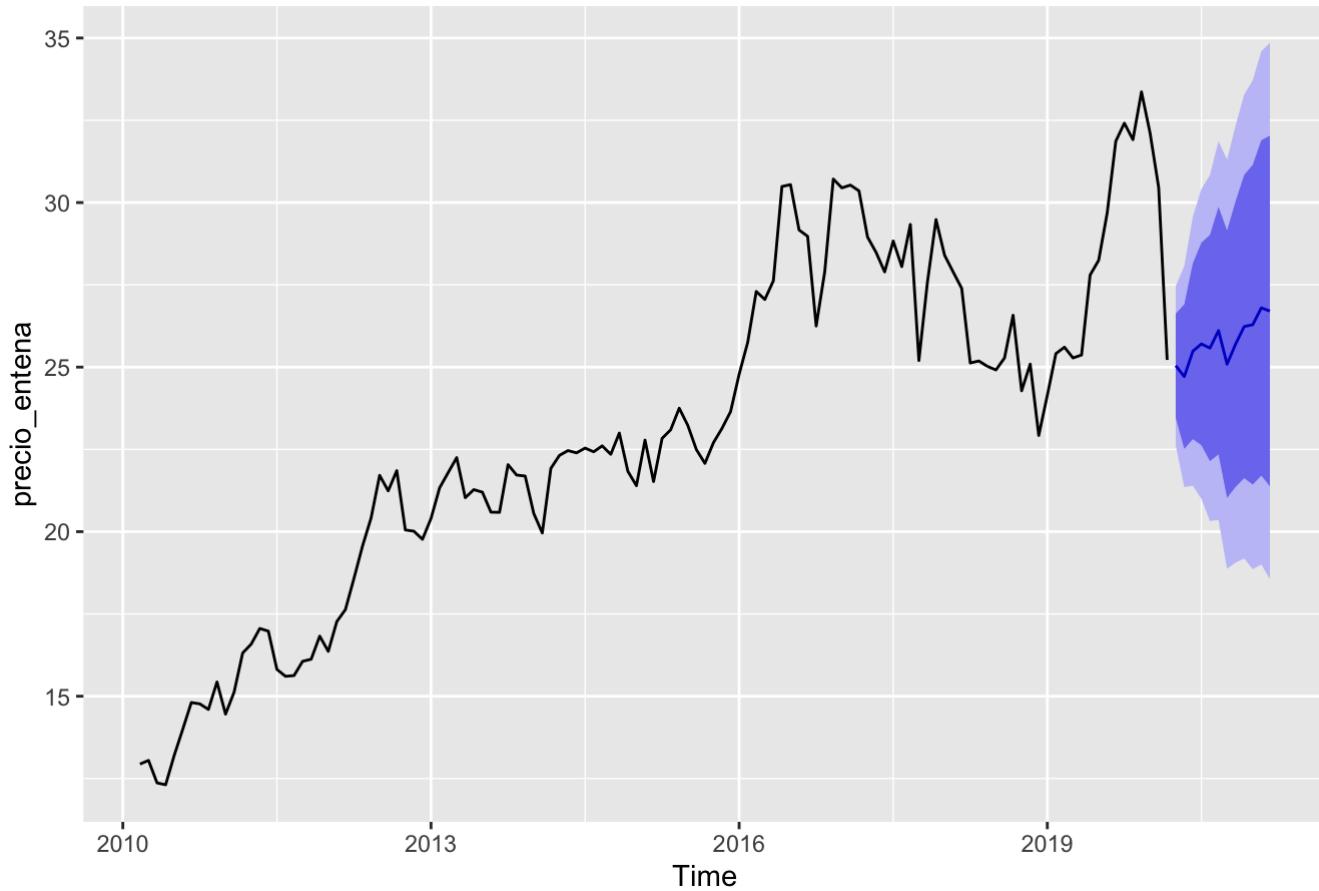
```

Forecasts from Holt's method



```
#Suavizado Holt-Winter
precio_hw <- hw(precio_entena, h=12)
autoplot(precio_hw)
```

Forecasts from Holt-Winters' additive method



```
knitr::kable(precio_hw, digits = 4,caption = "Predicciones ")
```

Predicciones

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Apr 2020	25.0436	23.4637	26.6235	22.6274	27.4598
May 2020	24.7114	22.5175	26.9053	21.3561	28.0667
Jun 2020	25.4832	22.8117	28.1547	21.3974	29.5690
Jul 2020	25.7048	22.6279	28.7818	20.9990	30.4106
Aug 2020	25.5793	22.1435	29.0152	20.3247	30.8340
Sep 2020	26.1094	22.3479	29.8709	20.3566	31.8622
Oct 2020	25.0892	21.0272	29.1512	18.8769	31.3015
Nov 2020	25.7030	21.3605	30.0455	19.0617	32.3443
Dec 2020	26.2325	21.6258	30.8392	19.1872	33.2778

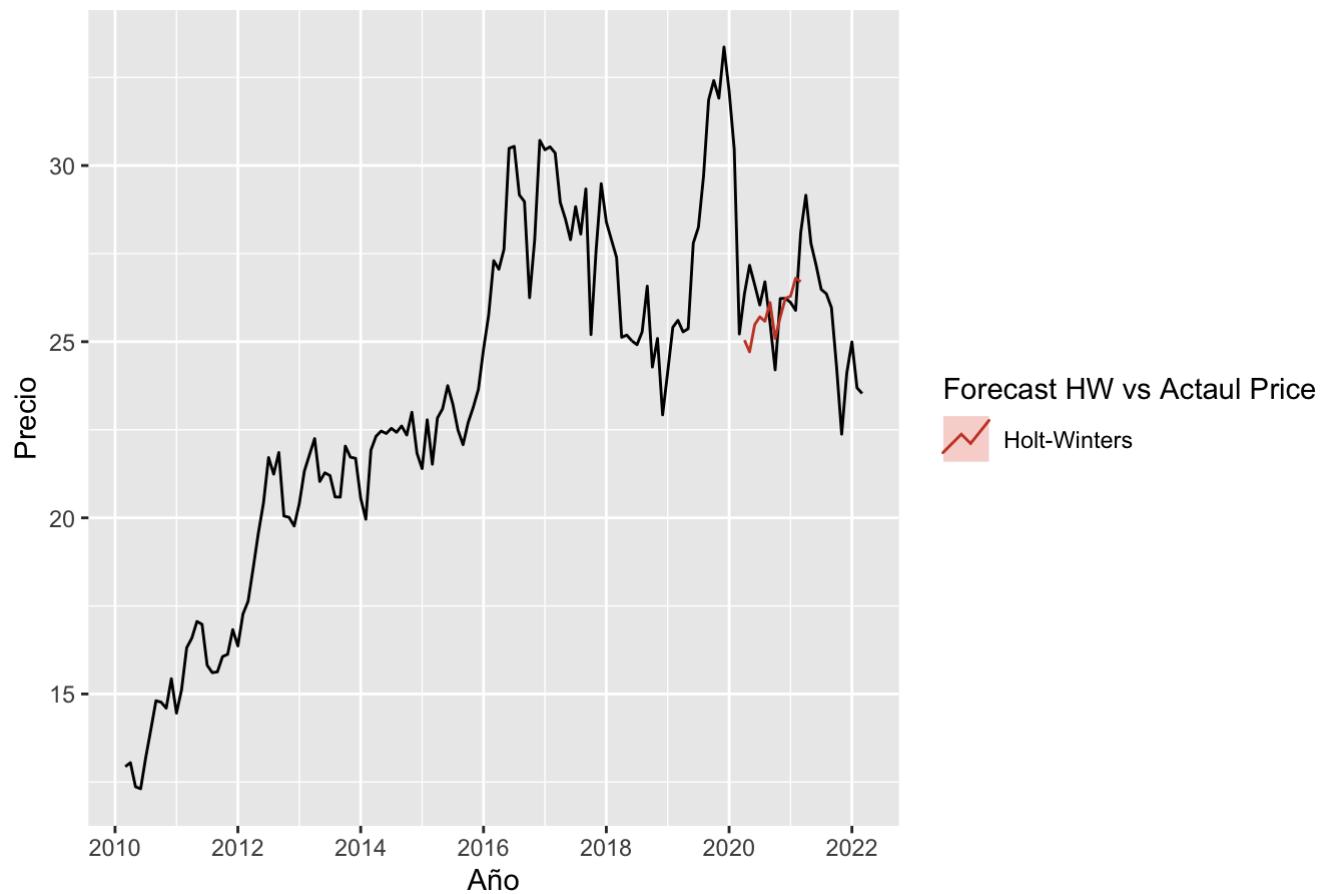
	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2021	26.2894	21.4321	31.1466	18.8609	33.7179
Feb 2021	26.8005	21.7044	31.8966	19.0066	34.5943
Mar 2021	26.7037	21.3787	32.0286	18.5599	34.8475

```
precio_hw[["model"]]
```

```
## Holt-Winters' additive method
##
## Call:
##   hw(y = precio_entena, h = 12)
##
##   Smoothing parameters:
##     alpha = 0.9621
##     beta  = 0.0014
##     gamma = 1e-04
##
##   Initial states:
##     l = 11.6503
##     b = 0.1077
##     s = 0.5308 0.127 0.1771 -0.2452 -0.7521 0.3754
##          -0.0473 0.1853 0.071 -0.5941 -0.1547 0.3266
##
##   sigma: 1.2328
##
##   AIC      AICc      BIC
## 647.7753 653.7170 695.3037
```

```
autoplot(close) + autolayer(forecast(precio_hw, h=12), series="Holt-Winters", PI=FALSE)
+ ggtitle("Predicciones de modelos") + xlab("Año") + ylab("Precio") + guides(colour=guide
e_legend(title="Forecast HW vs Actaul Price"))
```

Predicciones de modelos

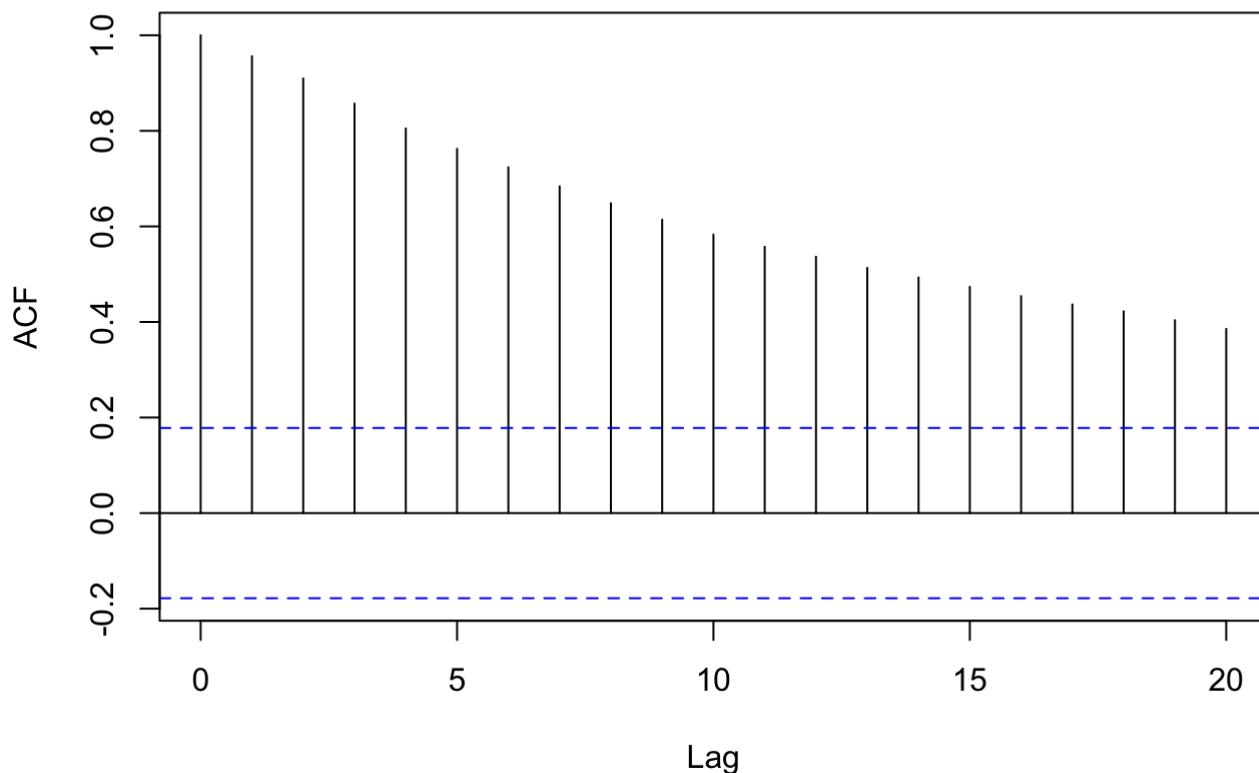


4. Hemos seleccionado el Modelo suavizado de *Holt-Winter* con un periodo de predicción de 12 meses. El modelo de Holt-winter nos da un aproximado de la predicción y el valor real en la fecha pronosticada.

5. Representar la serie y los correlogramas.

```
#Autocorrelacion simple
acf(ts(precio_entena, frequency=1))
```

Series ts(precio_entena, frequency = 1)



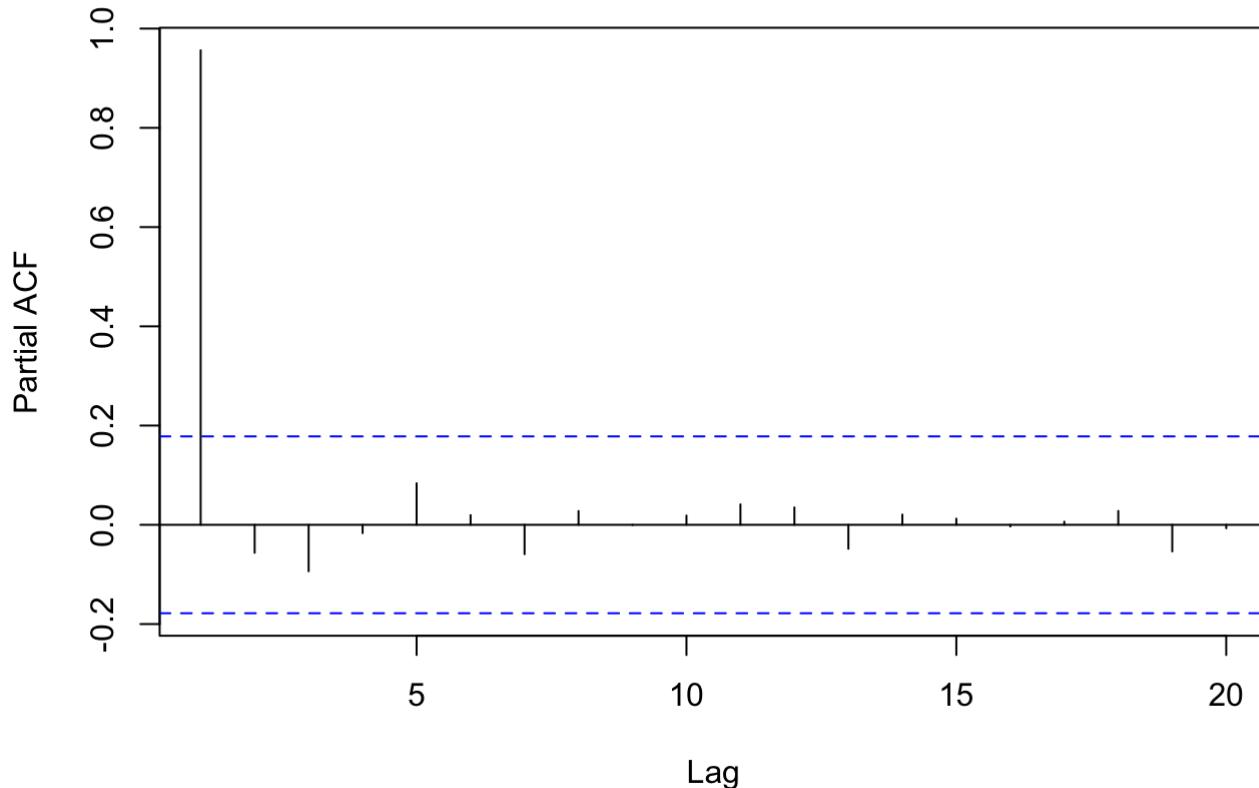
Vemos que nuestro gráfico de correlograma ACF decrece de manera lenta y también se observa que la media no es constante dado que la serie tiene tendencia.

```
adf.test(precio_entena, alternative="stationary")
```

```
## 
##  Augmented Dickey-Fuller Test
## 
## data:  precio_entena
## Dickey-Fuller = -2.4241, Lag order = 4, p-value = 0.4004
## alternative hypothesis: stationary
```

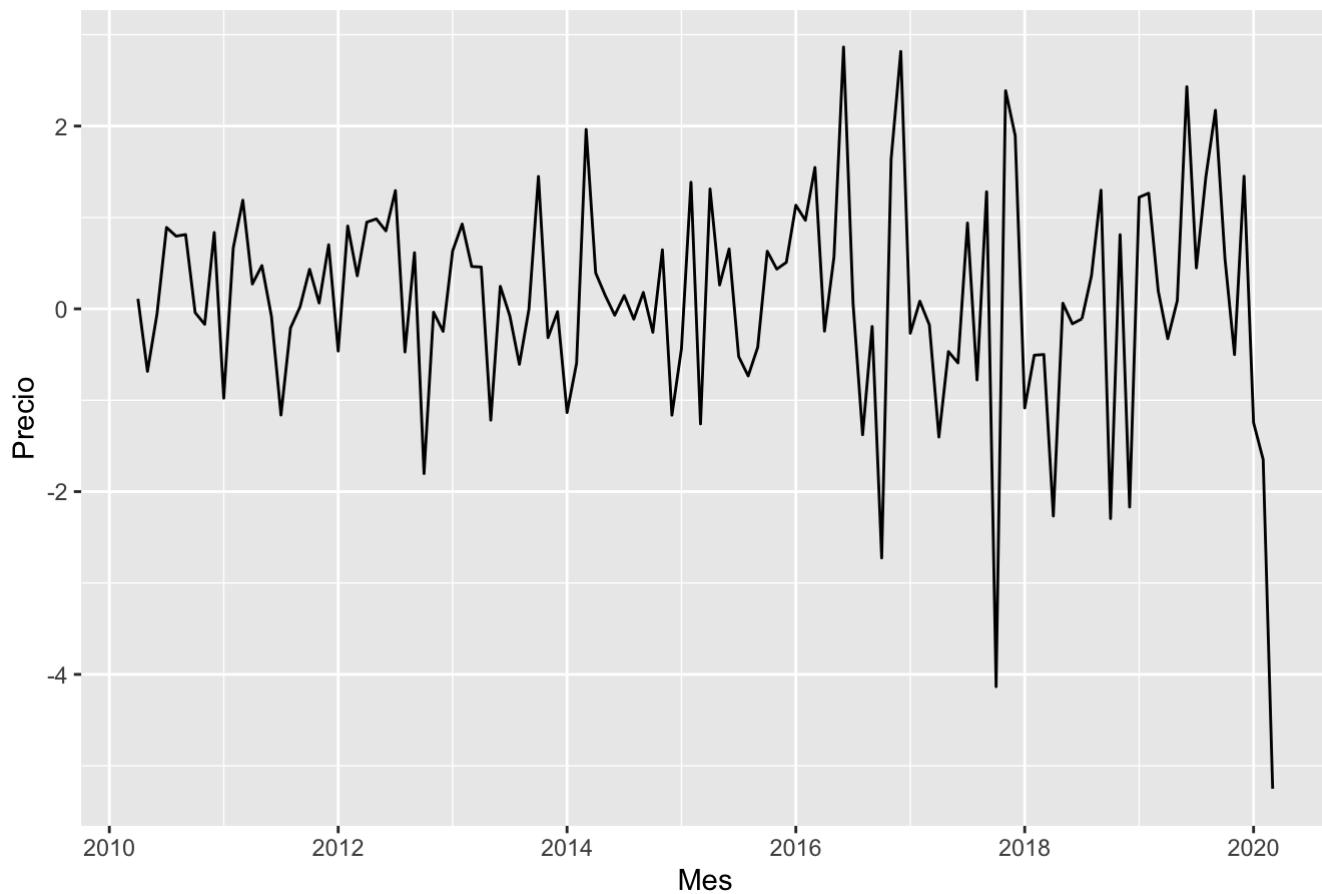
En el Augmented Dickey-Fuller Test el p-valor es mayor de 0.05 lo cual confirma que nuestra serie no es estacionaria.

```
#Autocorrelacion Parcial
pacf(ts(precio_entena, frequency=1)) # pedimos que la frecuencia sea igual que el resago
```

Series ts(precio_entena, frequency = 1)

```
preciodiff<-diff(precio_entena)
autoplot(preciodiff) + ggtitle("Precio de ATT") + xlab("Mes") + ylab("Precio")
```

Precio de ATT



En el grafico de Precio de ATT vemos los datos estan a lo largo de la media constante 0. y utilizamos el método Dickey-Fuller para confirmar la estacionariedad de la series.

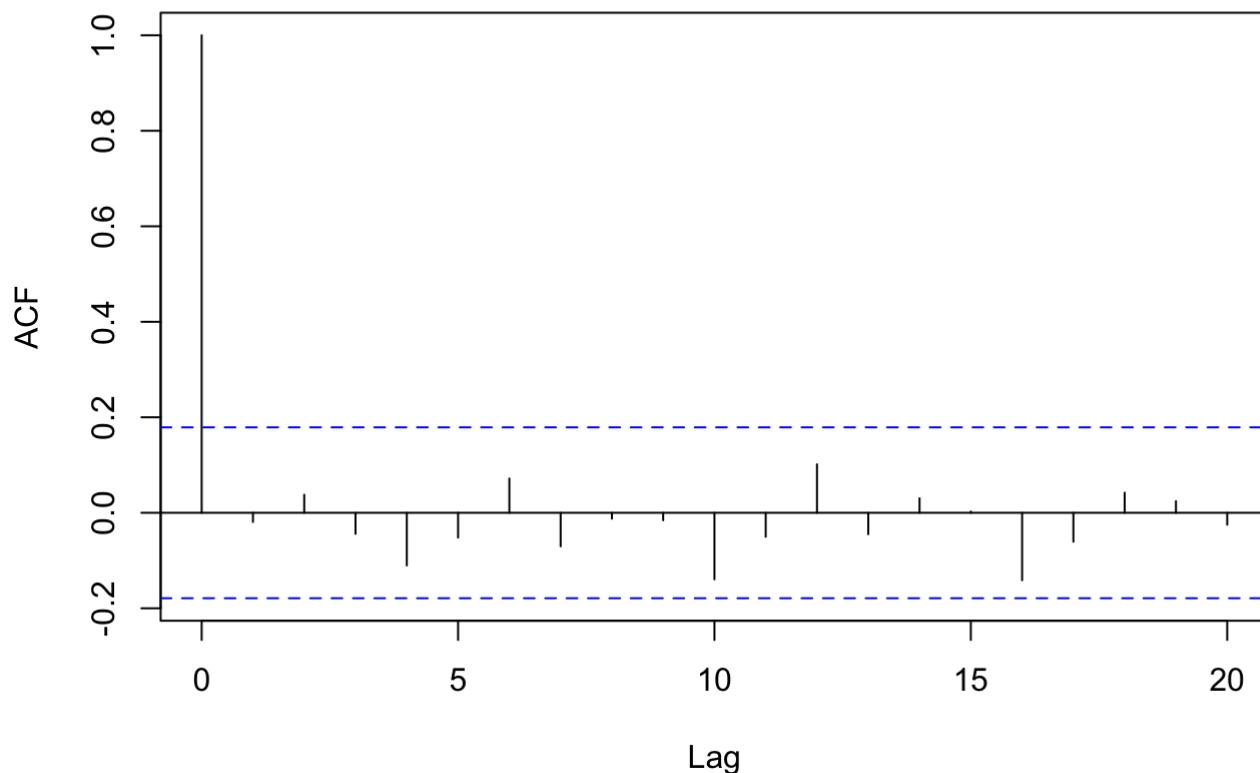
```
adf.test(preciodiff, alternative="stationary")
```

```
## Warning in adf.test(preciodiff, alternative = "stationary"): p-value smaller
## than printed p-value
```

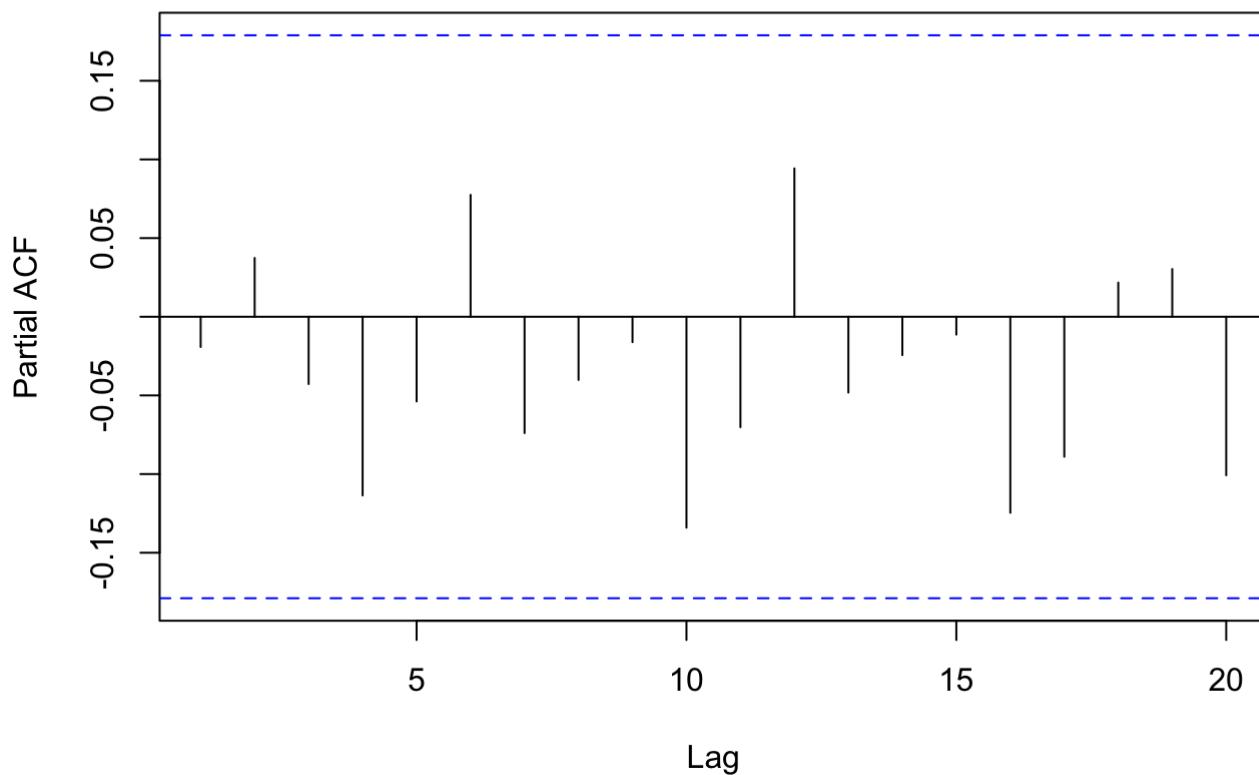
```
##
##  Augmented Dickey-Fuller Test
##
## data:  preciodiff
## Dickey-Fuller = -4.8811, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary
```

Una vez hecho el Augmented Dickey-Fuller Test podemos ver que la serie es menor que 0.05 por lo tanto es estacionaria.

```
acf(ts(preciodiff, frequency=1))
```

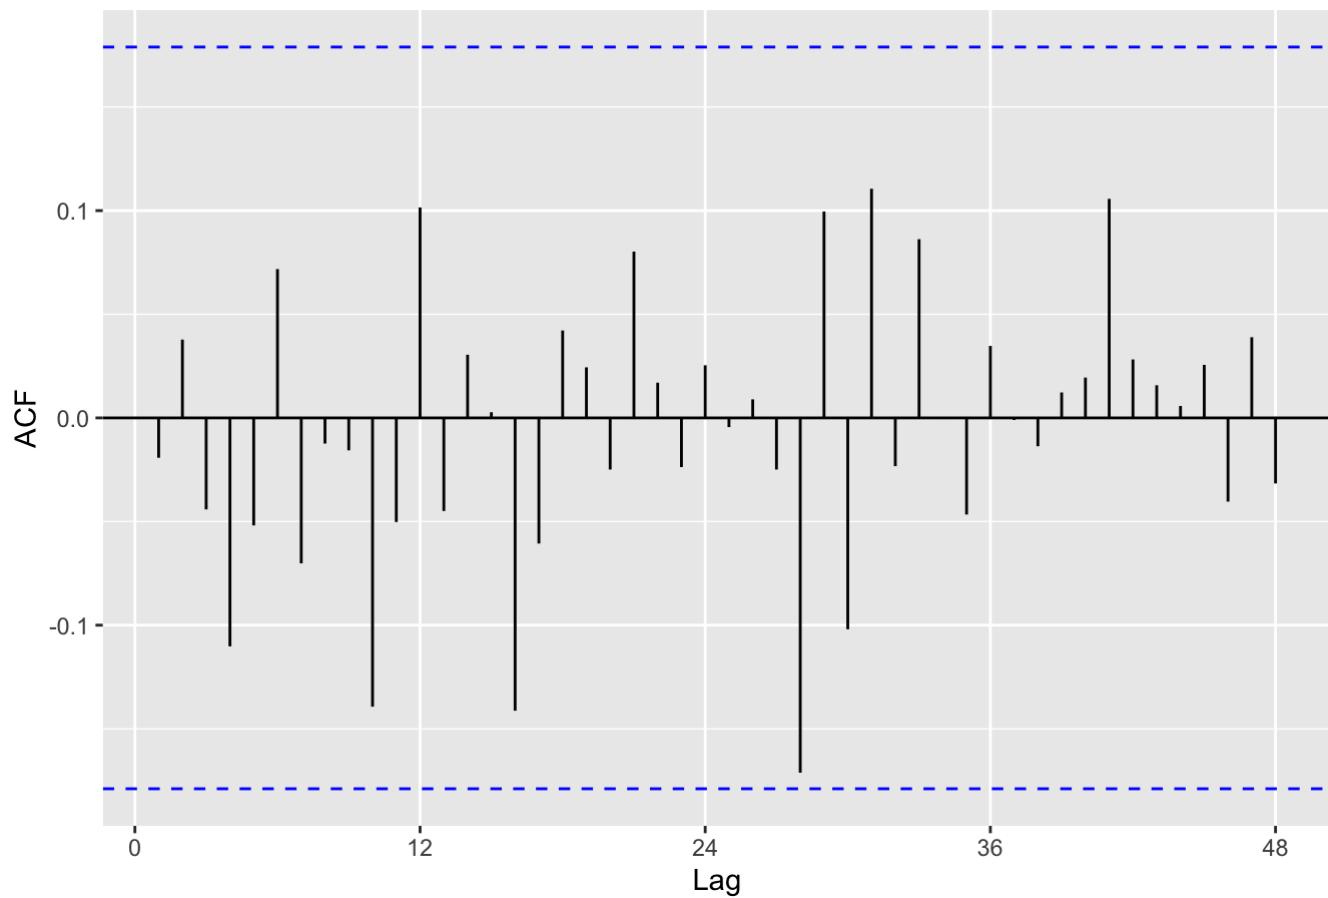
Series ts(preciodiff, frequency = 1)

```
pacf(ts(preciodiff, frequency=1))
```

Series ts(preciodiff, frequency = 1)

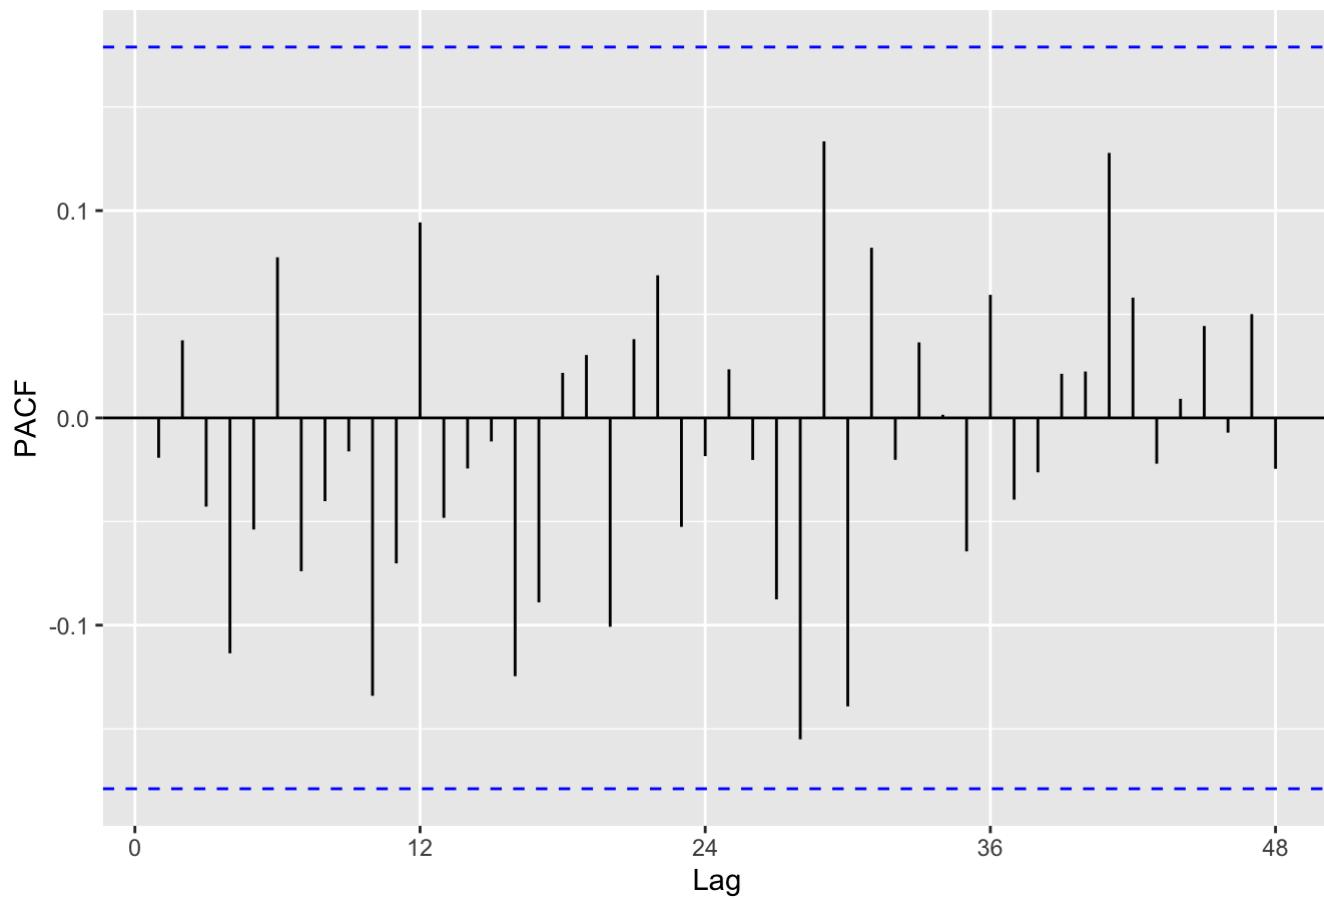
```
ggAcf(preciodiff, lag=48)
```

Series: preciodiff

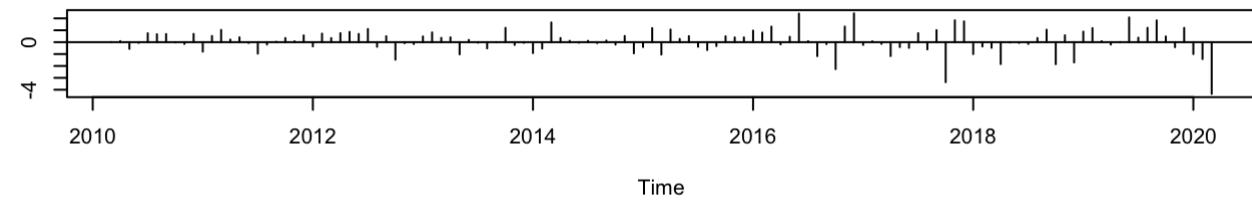
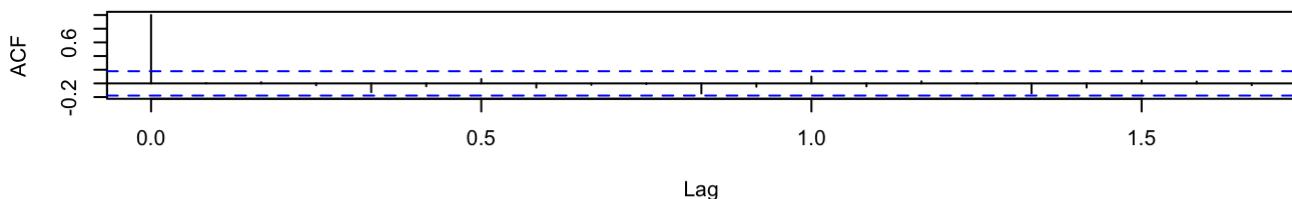
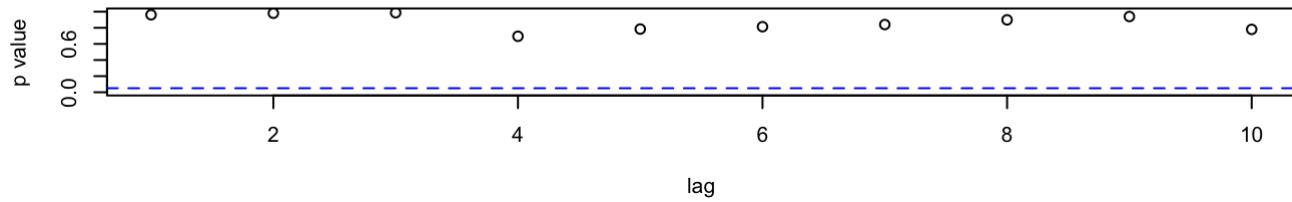


```
ggPacf(preciodiff, lag=48)
```

Series: preciodiff

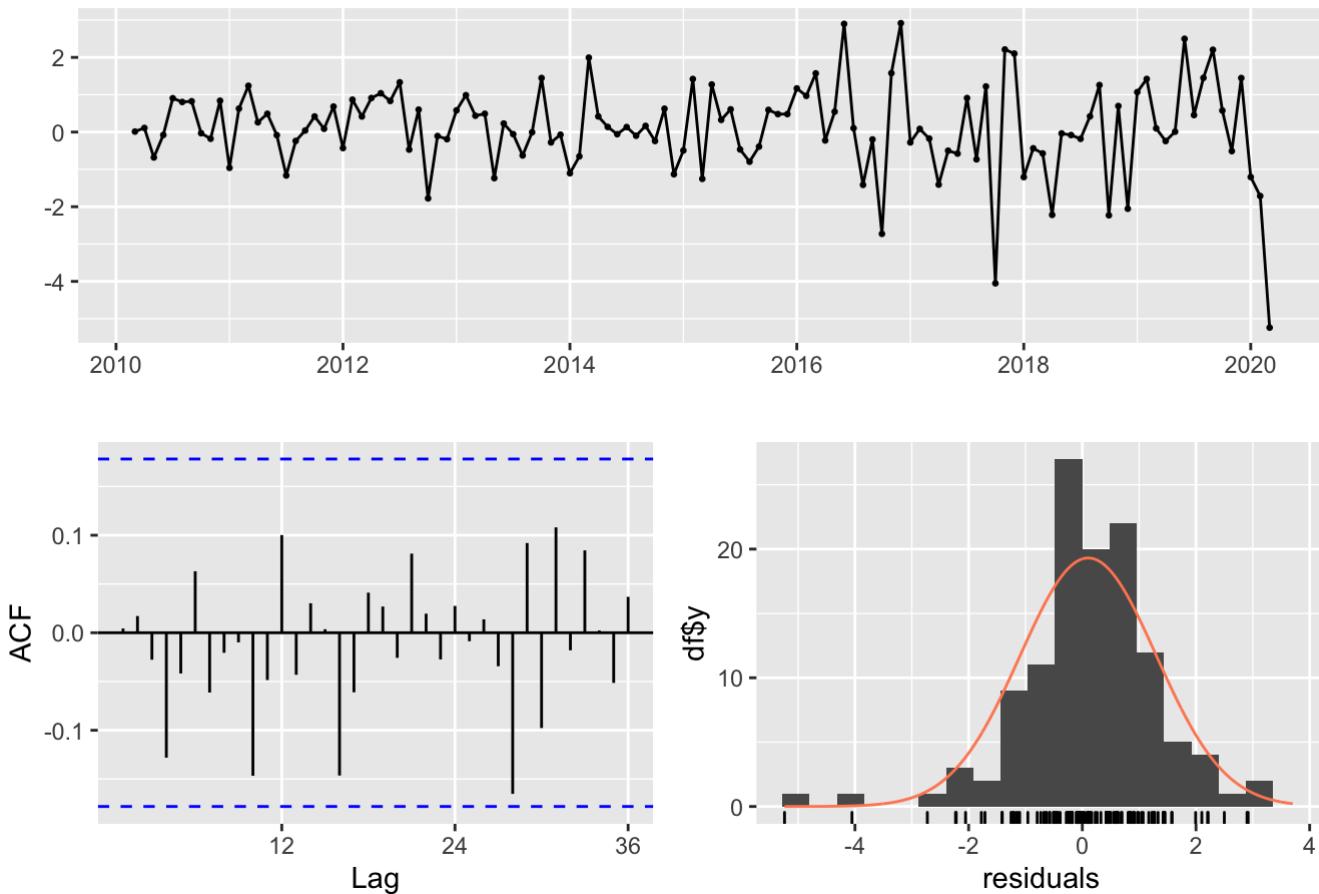


```
fitparon1<-arima(precio_entena, order=c(1,1,1))
tsdiag(fitparon1)
```

Standardized Residuals**ACF of Residuals****p values for Ljung-Box statistic**

```
checkresiduals(fitparon1)
```

Residuals from ARIMA(1,1,1)



```
##  
## Ljung-Box test  
##  
## data: Residuals from ARIMA(1,1,1)  
## Q* = 13.763, df = 22, p-value = 0.9097  
##  
## Model df: 2. Total lags used: 24
```

5. Puesto que el contraste de Ljung-Box nos da un p-value >0.05 aceptamos la hipotesis de que los residuos estan incorrelados y que nuestro modelo se ajusta bien . Lo podemos observar en su autocorrelograma, puesto que practicamente todos estan dentro de las bandas de cofianza.Nuestro mejor modelo es ARIMA(1,1,1).

6. Escribir la expresión algebraica del modelo ajustado con los parámetros estimados.

```
print(fitparon1)
```

```

## 
## Call:
## arima(x = precio_entena, order = c(1, 1, 1))
## 
## Coefficients:
##             ar1      ma1
##            -0.8538  0.8279
## s.e.    0.2935  0.3131
## 
## sigma^2 estimated as 1.45:  log likelihood = -192.55,  aic = 391.1

```

6. Teniendo en cuenta que los parámetros son -0.85 y -0.83, la expresión se construye de la siguiente manera:

$$(1 + 0.85B)(1 - B^{12})(1 - B)X_t = (1 - 0.83B^{12})Z_t$$

$$(1 + 0.85B)(1 - B^{12})(X_t - X_{t-1}) = -0.83Z_{t-12} + Z_t$$

$$(1 + 0.85B)(X_t - X_{t-12} - X_{t-1} + X_{t-13}) = -0.83Z_{t-12} + Z_t$$

$$X_t - X_{t-12} - X_{t-1} + X_{t-13} + 0.85X_{t-1} - 0.85X_{t-13} - 0.85X_{t-2} + 0.85X_{t-14} = -0.83Z_{t-12} + Z_t$$

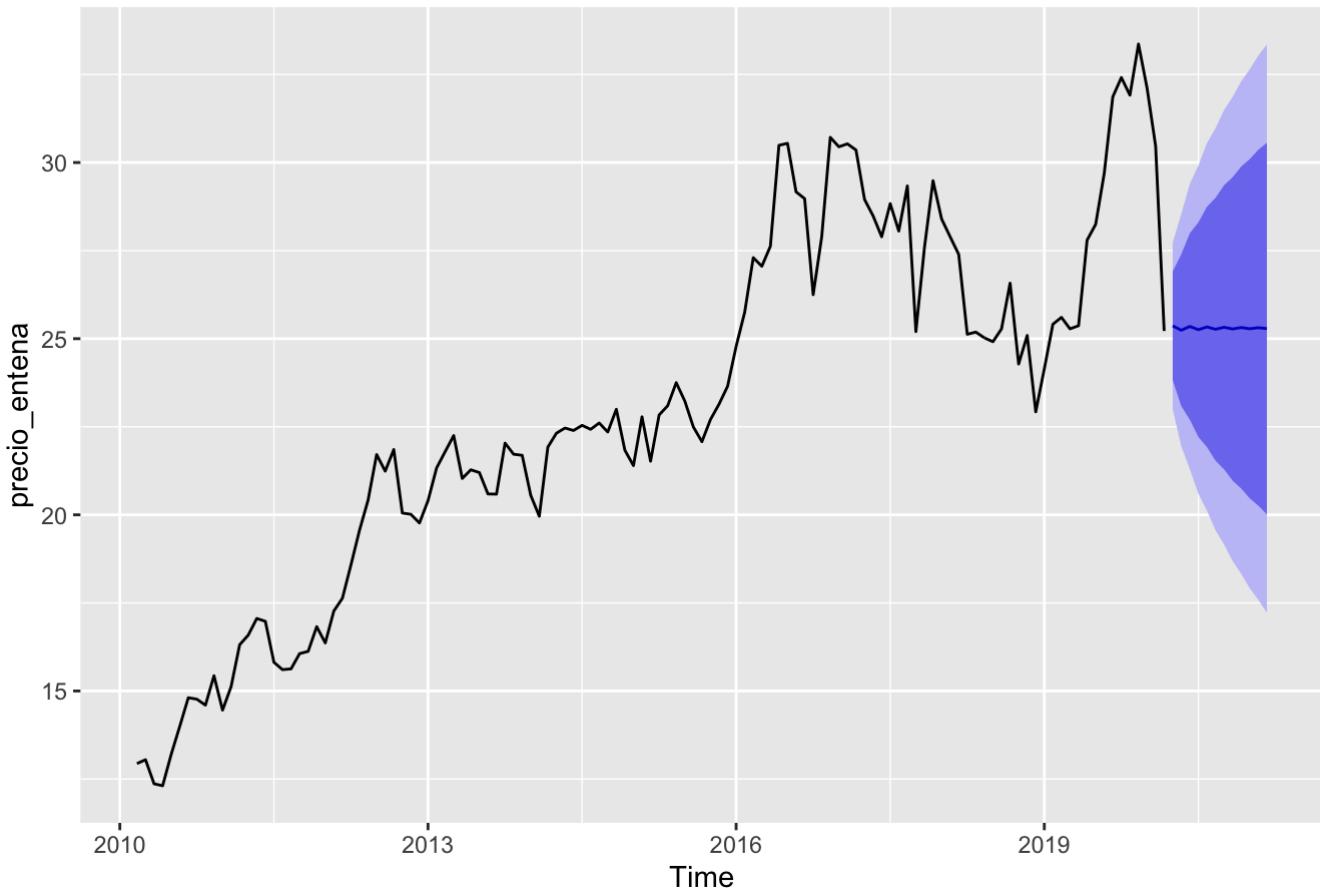
$$X_t = X_{t-12} + X_{t-1} - X_{t-13} + 0.85X_{t-1} - 0.85X_{t-13} - 0.85X_{t-2} + 0.85X_{t-14} - 0.83Z_{t-12} + Z_t$$

$$X_t = 1.85X_{t-1} - 0.85X_{t-2} + X_{t-12} - 1.85X_{t-13} + 0.85X_{t-14} - 0.83Z_{t-12} + Z_t$$

7. Calcular las predicciones y los intervalos de confianza

```
autoplot(forecast(fitparon1, h=12))
```

Forecasts from ARIMA(1,1,1)



```
forecast<-forecast(fitparon1,h=12)
knitr::kable(forecast(fitparon1,h=12),digits= 2,caption="Predicion Arima")
```

Prediccion Arima

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Apr 2020	25.37	23.82	26.91	23.01	27.73
May 2020	25.24	23.09	27.39	21.95	28.53
Jun 2020	25.35	22.70	27.99	21.30	29.39
Jul 2020	25.26	22.21	28.30	20.60	29.91
Aug 2020	25.33	21.92	28.74	20.12	30.55
Sep 2020	25.27	21.54	29.00	19.56	30.97
Oct 2020	25.32	21.29	29.36	19.16	31.49
Nov 2020	25.28	20.97	29.58	18.69	31.86
Dec 2020	25.32	20.75	29.89	18.33	32.30
Jan 2021	25.28	20.47	30.10	17.92	32.64
Feb 2021	25.31	20.26	30.36	17.59	33.04
Mar 2021	25.29	20.01	30.56	17.22	33.35

```
knitr::kable(precio_hw, digits =4,caption = "Prediccion Holt-Winters ")
```

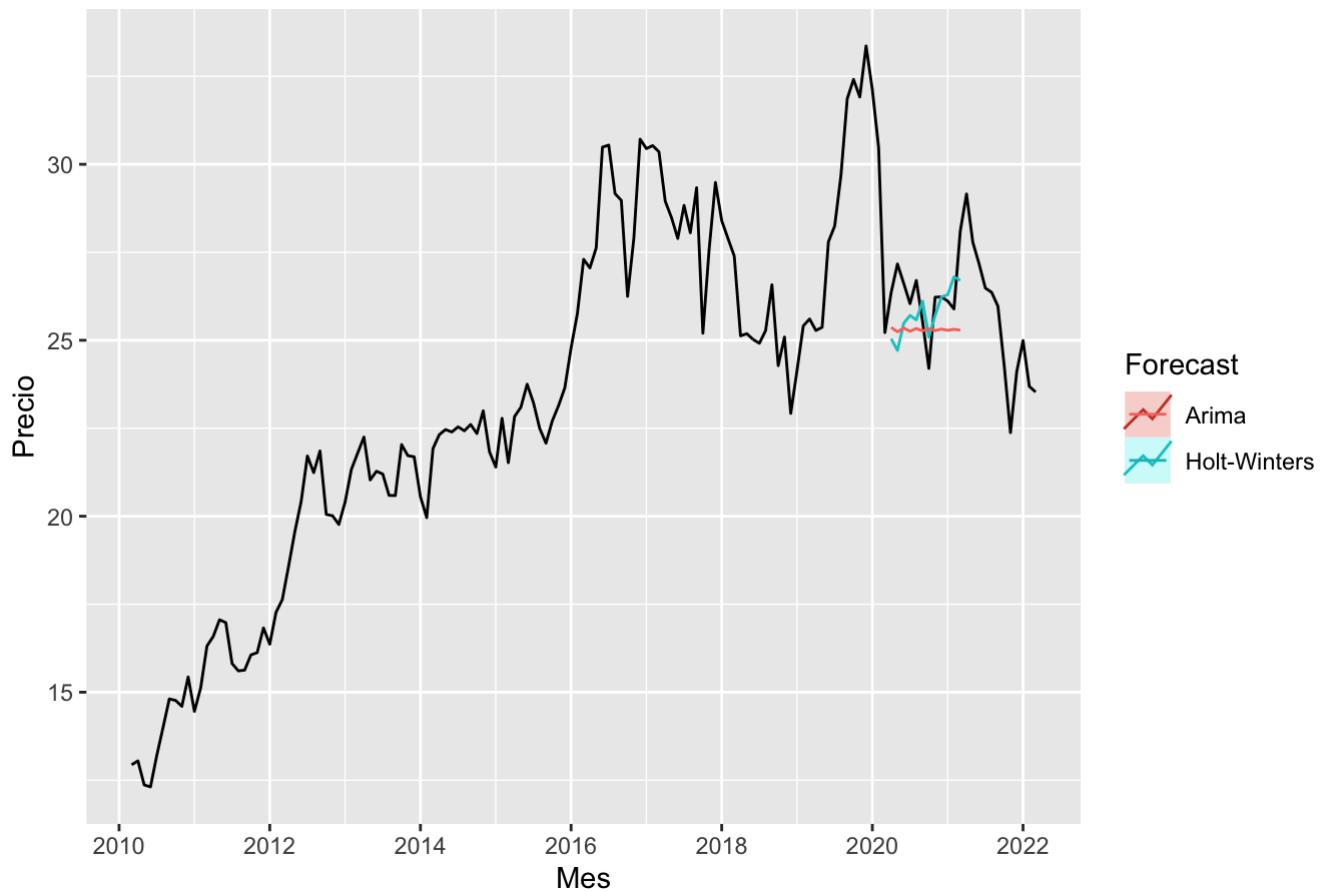
Prediccion Holt-Winters

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Apr 2020	25.0436	23.4637	26.6235	22.6274	27.4598
May 2020	24.7114	22.5175	26.9053	21.3561	28.0667
Jun 2020	25.4832	22.8117	28.1547	21.3974	29.5690
Jul 2020	25.7048	22.6279	28.7818	20.9990	30.4106
Aug 2020	25.5793	22.1435	29.0152	20.3247	30.8340
Sep 2020	26.1094	22.3479	29.8709	20.3566	31.8622
Oct 2020	25.0892	21.0272	29.1512	18.8769	31.3015
Nov 2020	25.7030	21.3605	30.0455	19.0617	32.3443
Dec 2020	26.2325	21.6258	30.8392	19.1872	33.2778
Jan 2021	26.2894	21.4321	31.1466	18.8609	33.7179

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Feb 2021	26.8005	21.7044	31.8966	19.0066	34.5943
Mar 2021	26.7037	21.3787	32.0286	18.5599	34.8475

```
autoplot(close) + autolayer(forecast(precio_hw, h=12), series="Holt-Winters", PI=FALSE)
+
autolayer(forecast$mean, series="Arima") + ggtitle("Predicciones de modelos") +
xlab("Mes") + ylab("Precio") + guides(colour=guide_legend(title="Forecast"))
```

Predicciones de modelos



8. Conclusion: En nuestro grafico de predicciones de modelos podemos observar que el modelo suavizado de *Holt-Winters* es el más similar a los datos reales. Este modelo de *Holt-Winters* imita la tendencia positiva de los datos reales e igualmente imita la declinación en el precio de la acción durante el mes de noviembre. En contraste con el modelo Arima que mantiene una tendencia que no refleja ninguna fluctuación en el precio de la acción y no se asimila a los datos reales.